Proyecto 1 — Early-warning: ¿cuánto va a durar este desvío?

Contexto

Tecfield opera flotas para transporte de personal. Un detector automático vigila que cada móvil siga su hoja de ruta: cuando el GPS se aleja más de 500 m de la ruta planificada, empieza a registrar *lecturas de desvío*. El problema operativo: cuando llega el **primer** ping de un desvío, nadie sabe si el evento se apaga solo en un minuto o si el móvil quedó afuera de la ruta por una hora. Este proyecto es construir ese early-warning.

El trabajo

Predecir, **al primer ping del evento**, cuántos segundos va a durar el desvío.

- La unidad de análisis no es la lectura: es el **evento**, dado por `grupoDesvioId`, que ya agrupa las lecturas consecutivas de una misma salida de ruta. No hay que construir la sesionización: ya está.
- Con el primer ping (`t0`*) hay que producir un número: la duración esperada del evento.

La variable objetivo (y)

- `y` = `max(fechaHoraRastreo) − min(fechaHoraRastreo)` dentro del `grupoDesvioId`, en **segundos**.
- El reloj es `fechaHoraRastreo` (la fecha del punto GPS), **no** `timestamp` (el instante en que el detector escribió el registro). No son lo mismo.
- * `t0` = `min(fechaHoraRastreo)` del `grupoDesvioId`. El evento tiene más pings; esos no son `t0`.

Reglas de armado del panel (a ustedes les toca programarlas):

- Entrenar solo con grupos de `n ≥ 2` lecturas y duración `> 0`.
- El detector topea a 4 h: duraciones mayores no son un retorno medido.

Posibles variables predictoras

Ustedes deciden la selección final; éstas son candidatas razonables:

- Del primer ping del desvío:
  - `distanciaMinima` — metros hasta la ruta planificada más cercana.
  - `velocidad` del móvil (y un flag de velocidad vacía: distingue detenido de tránsito).
  - `rutaMasCercana` — cuál de los tres recorridos de la hoja era la más cercana.
  - `posicion` (lat/lon) y hora/franja del `t0`.
- De la hoja de ruta, **si** el join alcanza:
  - `vehiculo.tipoVehiculo` — criticidad.
  - `tipoHDR`, `obra_id`.
  - Largo y duración del recorrido según OSRM (`geometriaOSRM`).
- De la telemetría **anterior** a `t0` (5–10 minutos antes):
  - Velocidad y rumbo previos del mismo móvil (`rastreoSatelital`).

Los datos

Formato general de todos los archivos:

- JSON estilo mongoexport: un array `[{...}, {...}]` de documentos.
- Sin PII: los identificadores van seudonimizados con el mismo código en todos los archivos — `VEH_*` (vehículo), `EMP_*` (empleado), `OBR_*` (obra). Los cruces entre archivos funcionan con esos seudónimos tal cual.

Colecciones entregadas:

- **`desviosHojaRuta.json`** — las lecturas del detector. Se pueden entregar más en meses posteriores para aumentar el dataset. Campos clave:
  - `grupoDesvioId` — el evento. **Agrupar por acá.**
  - `hojaDeRutaId` — la hoja contra la que se midió el desvío.
  - `flotaId` (`VEH_*`), `fechaHoraRastreo`, `posicion` (`[lat, lon]` — ¡invertido respecto del GPS!), `distanciaMinima`, `velocidad`,
  - `rutaMasCercana`, `retorno.detectado` / `retorno.motivo` / `retorno.timestamp`,
  - `tipoHDR`.
- **`hojaDeRuta.json`** — el plan del viaje: recorrido, paradas, pasajeros esperados y `geometriaOSRM` (trazado sobre calles reales con su duración y distancia). Solo las hojas citadas por los desvíos entregados.
- **`rastreoSatelital.json`** — telemetría GPS de los vehículos involucrados: `flotaID` (`VEH_*`), `fecha`, `location.coordinates` (`[lon, lat]`), `velocidad`.

Joins y llaves

- Desvío → hoja de ruta: `hojaDeRutaId` = `hojaDeRuta._id`. No inventar hojas: el modelo mínimo (solo primer ping) cierra sin ese join.
- Desvío → GPS: `flotaId` = `flotaID` y tiempos (`fechaHoraRastreo` vs `fecha`).
- El vehículo viaja como el mismo `VEH_*` en los tres archivos.

Avisos prácticos

- **Coordenadas invertidas**: `posicion` en desvíos es `[lat, lon]`; `location.coordinates` en GPS es `[lon, lat]`. Invertirlas produce puntos plausibles en el mapa equivocado (¿océano?): graficar siempre antes de usar.
- Tirar lecturas con `posicion == [0,0]` o `fechaHoraRastreo` fuera de 2025–2026.
- No recortar por día: cortaría eventos a la medianoche y partiría grupos.
- **Fugas** (fuera de `X`, siempre): `retorno.*` (es el desenlace), número de lecturas del grupo, GPS posterior a `t0`, distancias/posiciones posteriores, y cualquier ratio de desvío calculado con el final del evento.

Qué se espera

- Panel evento-a-evento con el `y` definido arriba y las reglas de limpieza.
- Un baseline simple (la mediana de duración) y un modelo que use solo información de `t0`.
- Comparación honesta contra el baseline, con split por vehículo.
- Un informe donde el análisis exploratorio justifique las decisiones.