



Departamento Teoría de la Computación
Facultad de Informática
Universidad Nacional del Comahue

Laboratorio de inteligencia artificial

Trabajo Práctico Obligatorio Nº 1

Parte 1: entendimiento del problema y trabajos relacionados

Predicción de la duración de desvíos de ruta en flotas de transporte de personal

Apellido y Nombre	**Legajo**	**Email**
Reibold, Sebastian Alejandro	FAI-3854	sebastian.reibold@est.fi.uncoma.edu.ar
Fernandez Gramajo, Bautista	FAI-3874	bautista.fernandez@est.fi.uncoma.edu.ar
Kissner, Davor	FAI-3185	davor.kissner@est.fi.uncoma.edu.ar

Cursado 2026 — 7 de noviembre de 2026

Índice

1. Introducción **2**

2. Motivación **2**

3. Objetivos **3**
3.1. Objetivo general 3
3.2. Objetivos específicos 3

4. Trabajos relacionados **3**
4.1. Predicción de desvíos en rutas de última milla [1] 3
4.2. Predicción de la duración de incidentes viales [2] 4
4.3. Detección online de trayectorias anómalas [3] 4
4.4. Modelos de duración basados en riesgo [4] 5
4.5. Comparación 5

1. Introducción

Este trabajo se enmarca en el convenio entre la empresa Tecfield SRL y la Facultad de Informática de la UNComa, en la materia Laboratorio de Inteligencia Artificial. Tecfield cuenta con un detector automático que compara la posición GPS de cada vehículo contra su hoja de ruta y registra un evento cuando la distancia supera los 500 metros. En el instante en que aparece el primer punto fuera de ruta, la sala de monitoreo no puede anticipar si el desvío durará minutos o más de una hora, lo que dificulta priorizar la atención entre un volumen alto de alertas.

El proyecto busca estimar, en ese primer instante, la duración esperada del desvío. El trabajo completo se presenta en tres documentos. Este primero plantea el problema, los objetivos y los trabajos relacionados. El segundo describe los datos y la construcción del corpus. El tercero presenta los modelos, las métricas y los resultados.

2. Motivación

Tecfield SRL opera flotas de vehículos dedicadas, principalmente, al transporte de personal hacia obras y yacimientos de la región. Cada vehículo tiene asignada una *hoja de ruta* con un recorrido planificado, y un detector automático compara periódicamente su posición GPS contra la geometría de ese recorrido. Cuando la distancia supera un umbral (actualmente 500 metros), el detector registra un *evento de desvío* y agrupa las lecturas consecutivas que permanecen fuera de ruta bajo un mismo identificador. El evento se cierra cuando el vehículo retoma la ruta o cuando se alcanza el tope de cuatro horas del detector, en cuyo caso no hay un retorno efectivamente medido.

El problema surge en el instante en que aparece el primer punto fuera de ruta (que en adelante llamamos T_0). En ese momento la sala de monitoreo no tiene forma de distinguir una separación momentánea —el vehículo toma una calle alternativa y retoma la ruta en uno o dos minutos— de un evento prolongado que puede extenderse durante una hora o más. Como el detector está en producción desde 2026 y genera del orden de 100.000 lecturas por mes, el volumen de alertas es alto y todas se atienden con la misma prioridad. Esto satura la atención de los operadores y hace que los recursos de monitoreo no se destinen necesariamente a los casos que más lo requieren.

Un agravante es que no existen etiquetas humanas confiables sobre el motivo de cada desvío (falla de GPS, hoja de ruta mal configurada, vehículo mal asignado, recorrido operativo distinto del plan), por lo que no es posible entrenar un clasificador de desvíos "relevantes" versus "irrelevantes". Lo que sí queda registrado de manera sistemática es *cuánto duró* cada evento. Esto convierte a la duración en una variable objetivo disponible, objetiva y directamente útil para la operación.

Contar con una estimación temprana de la duración esperada de un desvío, calculada en T_0 y sólo con información conocida hasta ese instante, permitiría priorizar la atención de las alertas más críticas desde el momento en que se generan, en lugar de esperar a que el evento se resuelva por sí mismo o alcance el tope del detector. En otros términos, se trata de construir un mecanismo de *alerta temprana* (*early warning*) sobre un evento que ya fue detectado, pero cuya gravedad todavía se desconoce. La importancia de la solución es que para Tecfield, reduce la carga de trabajo en monitoreo y mejora el tiempo de reacción ante desvíos largos.

3. Objetivos

3.1. Objetivo general

Desarrollar un prototipo que permita estimar, en el momento en que se detecta el primer punto fuera de ruta de un vehículo (T_0), la duración esperada del evento de desvío, de modo de apoyar la priorización de alertas en la sala de monitoreo de Tecfield.

3.2. Objetivos específicos

1. **Construir** un panel evento-a-evento a partir de las colecciones provistas por Tecfield (`desviosHojaRuta`, `hojaDeRuta` y `rastreoSatelital`), con la duración observada de cada evento como variable objetivo.
2. **Analizar** el conjunto de datos construido para caracterizar la distribución de duraciones, la calidad y cobertura de las variables disponibles en T_0, y las limitaciones del corpus.
3. **Desarrollar** un modelo predictivo que estime la duración del evento utilizando exclusivamente la información conocida hasta T_0.
4. **Evaluar** el desempeño del modelo frente a referencias simples (*baselines*) mediante una separación de los conjuntos de entrenamiento y prueba por vehículo, analizando el error según distintos segmentos de interés operativo.

4. Trabajos relacionados

El problema se ubica en la intersección de tres líneas de investigación bien establecidas: la predicción de desvíos respecto de rutas planificadas, la detección de trayectorias anómalas a partir de GPS y la predicción de la duración de incidentes viales. A continuación se describen cuatro trabajos representativos y se analiza qué aporta cada uno al proyecto.

4.1. Predicción de desvíos en rutas de última milla [1]

Se estudia sobre datos reales de una empresa de logística noruega, si es posible predecir que un conductor se desviará de la ruta planificada por el sistema de optimización y cuantificar la magnitud de ese desvío. Disponen de la ruta planificada y de la ruta realmente ejecutada para 19.647 rutas, 400 conductores y más de 10.000 ubicaciones, y el dataset fue publicado. La hipótesis central es que los desvíos no son aleatorios sino manifestaciones del *conocimiento tácito* del conductor.

Se definen tres métricas de desvío entre ruta planificada y real (calidad de la secuencia de paradas, distancia de edición normalizada y variación relativa de la distancia total) y las usan para construir dos tareas: una regresión que estima el grado de desvío y una clasificación binaria (desviada / no desviada) según umbrales sobre las tres métricas. Las variables de entrada son propiedades estáticas (identificador del conductor, día de la semana, país, cantidad de paradas, experiencia reciente) y secuenciales (secuencia de paradas, tipo de parada, si es depósito). Proponen una arquitectura de red neuronal con *embeddings* y un bloque secuencial intercambiable (LSTM, atención o CNN), y la comparan contra cuatro *benchmarks*: promedio histórico global, promedio histórico por conductor y día, Random Forest y perceptrón multicapa. La evaluación usa una partición temporal (entrenamiento con rutas antiguas, prueba con las más recientes) estratificada por conductor y día, con MSE, RMSE y MAE para regresión. Reportan mejoras del 9–19 % en regresión respecto de los *benchmarks*.

Relación con el proyecto. Es el trabajo más cercano en cuanto a contexto: ruta planificada versus ruta real, datos operativos de una empresa y predicción de desvíos. Son directamente reutilizables (i) la metodología de evaluación contra *benchmarks* simples basados en promedios históricos, (ii) el protocolo de agregar variables de manera incremental y conservar sólo las que mejoran, y (iii) el conjunto de métricas de regresión. La diferencia principal es el momento y la unidad de predicción: ellos predicen *antes* de que comience el viaje, a nivel de ruta completa, si habrá desvío y cuánto se alterará la secuencia de paradas; nosotros predecimos *durante* el viaje, a nivel de evento ya detectado, cuánto tiempo durará. Además, la variable objetivo de ellos es una similitud acotada en $[0, 1]$, mientras que la nuestra es una duración en segundos con distribución muy asimétrica. La arquitectura secuencial con LSTM no aplica directamente porque en T_0 no hay secuencia de paradas, aunque podría considerarse si se incorpora la telemetría previa como serie temporal. También difiere el criterio de partición: ellos separan por fecha y estratifican por conductor, de modo que cada conductor aparece en los tres subconjuntos, mientras que en nuestro caso se separa por vehículo justamente para impedir que el modelo memorice el comportamiento de un móvil visto en entrenamiento.

4.2. Predicción de la duración de incidentes viales [2]

Se aborda la predicción de cuánto durará un incidente de tránsito (accidente, avería, obstrucción) a partir de la información disponible en el reporte inicial, sobre tres conjuntos de datos de arterias y autopistas de Sídney y San Francisco. Proponen un marco *bi-nivel*: primero un clasificador decide si el incidente será corto o largo, buscando el umbral que equilibra las clases y el desempeño; luego un modelo de regresión específico para cada grupo estima la duración en minutos. Incorporan un procedimiento de remoción de valores atípicos y una técnica de optimización conjunta (IEO-ML) que extiende varios modelos base de aprendizaje automático. Una conclusión relevante es que los incidentes cortos y largos deben modelarse por separado, y que el enfoque propuesto supera a los modelos base en la mayoría de los escenarios analizados.

Relación con el proyecto. Este trabajo resuelve un problema estructuralmente idéntico al nuestro aunque en otro dominio: predecir la duración de un evento en el momento en que se lo detecta, con información parcial, sobre datos operativos con fuerte asimetría y valores extremos. Son aplicables (i) la idea de tratar por separado los eventos cortos y largos, posiblemente como una etapa de clasificación previa a la regresión, (ii) el tratamiento explícito de *outliers* en la variable objetivo, que se corresponde con nuestra tarea de definir umbrales para eventos anómalamente cortos o largos, y (iii) el uso de modelos basados en árboles y ensambles como línea principal. La diferencia está en las variables de entrada: los reportes de incidentes incluyen tipo de incidente, cantidad de carriles afectados, condiciones climáticas y flujo de tráfico, mientras que nosotros contamos principalmente con variables geoespaciales y de telemetría del propio vehículo.

4.3. Detección online de trayectorias anómalas [3]

iBOAT es un método para detectar en tiempo real si la trayectoria GPS de un taxi se aparta de las rutas "normales" históricas entre un origen y un destino, e identificar qué tramo es responsable de la anomalía. La ciudad se discretiza en una grilla, cada trayectoria se representa como secuencia de celdas y, a medida que llegan nuevos puntos, se calcula el soporte que tiene el tramo reciente en las trayectorias históricas: un soporte bajo indica anomalía. Lo evalúan sobre las trayectorias de 7.600 taxis durante un mes, con desempeño cercano al máximo (AUC $\geq 0{,}99$), y analizan unas 43.800 trayectorias anómalas, encontrando que la mayoría corresponde a fraudes deliberados de los conductores.

Relación con el proyecto. iBOAT resuelve la etapa *anterior* a la nuestra: decidir si un vehículo está fuera de ruta. Tecfield ya tiene resuelto ese paso con un detector propio basado en distancia a la geometría de la hoja de ruta, por lo que no necesitamos reimplementarlo. El trabajo es útil por dos motivos. Primero, muestra cómo representar y comparar trayectorias GPS contra un patrón de referencia, lo que sugiere variables para T_0 (por ejemplo, cuán "frecuente" es la zona donde se produce el desvío en el historial del vehículo o de la obra). Segundo, ilustra que las anomalías detectadas mezclan causas muy distintas (fraude, cortes de calle, rutas alternativas legítimas), lo que refuerza la limitación de nuestro corpus: los eventos de desvío incluyen tanto desvíos reales como falsos desvíos por fallas de GPS o hojas mal configuradas, sin etiqueta que los distinga. La diferencia central es que iBOAT es un problema no supervisado de detección, mientras que el nuestro es supervisado de regresión.

4.4. Modelos de duración basados en riesgo [4]

Se modela la duración de incidentes en autopistas mediante modelos de supervivencia (*hazard-based*), en los que la variable de interés es el tiempo hasta que el evento finaliza y la función de riesgo describe la probabilidad de que termine en el instante siguiente, dado que aún no terminó. Ajustan distribuciones paramétricas (Weibull, log-logística, log-normal) por tipo de incidente y estudian qué factores aceleran o retrasan la finalización.

Relación con el proyecto. Este enfoque es relevante por una característica particular de nuestros datos: los eventos que alcanzan el tope de cuatro horas del detector no tienen un final observado, es decir, son observaciones *censuradas por la derecha*. Los modelos de supervivencia están diseñados exactamente para incorporar ese tipo de casos en lugar de descartarlos, lo que podría aprovechar información que un modelo de regresión convencional pierde. En la primera etapa del proyecto se seguirá la regla indicada en la consigna, que separa esos eventos por no corresponder a un retorno medido; este trabajo queda como referencia para una eventual extensión en la que se los trate como datos censurados. También aporta la idea de que la distribución de duraciones suele ser log-normal o Weibull, lo que justifica evaluar una transformación logarítmica de la variable objetivo.

4.5. Comparación

La Tabla 1 resume los trabajos analizados frente a la propuesta de este proyecto.

	Konovalenko 2026	**Grigorev 2022**	**Chen 2013**	**Hojati 2013**	**Este proyecto**
Problema	Predecir si una ruta será desviada y cuánto	Predecir duración de incidentes viales	Detectar en línea trayectorias anómalas	Modelar duración de incidentes	Predecir duración de un desvío ya detectado
Tipo de tarea	Regresión + clasificación	Clasificación (corto/largo) + regresión	Detección no supervisada	Análisis de supervivencia	Regresión
Momento de predicción	Antes de iniciar la ruta	Al reportarse el incidente	En cada nuevo punto GPS	Al reportarse el incidente	En el primer ping fuera de ruta (T_0)
Unidad	Ruta completa	Incidente	Trayectoria origen–destino	Incidente	Evento (`grupoDesvioId`)
Datos	19.647 rutas planificadas y reales, 400 conductores	Reportes de incidentes de 3 redes viales (AU, EE.UU.)	GPS de 7.600 taxis, un mes	Reportes de incidentes en autopistas	Lecturas del detector (jul–ago 2026), hojas de ruta, GPS
Variables	Conductor, día, país, largo, experiencia, secuencia de paradas	Tipo de incidente, carriles, clima, tráfico	Secuencia de celdas de grilla	Tipo de incidente, ubicación, hora	Distancia a ruta, velocidad, posición, hora, tipo de vehículo y hoja, telemetría previa
Modelos	Redes con embeddings + LSTM/atención/CNN; RF y MLP como benchmark	Ensambles de árboles y otros modelos base; marco bi-nivel	Soporte de subtrayectorias sobre histórico	Weibull, log-logística, log-normal	Árbol de decisión y Random Forest
Evaluación	Partición temporal estratificada; MSE, RMSE, MAE	Múltiples escenarios de validación; error en minutos	AUC contra trayectorias etiquetadas	Bondad de ajuste, análisis de factores	Partición por vehículo; MAE, RMSE, error mediano
Qué se toma	Benchmarks históricos, selección incremental de variables, métricas de regresión	Separar cortos y largos; manejo de outliers; ensambles	Representación de trayectorias; conciencia de causas mixtas	Tratamiento de censura (tope de 4 h); transformación log	—
Qué no aplica	Predicción previa al viaje; secuencia de paradas; su partición es temporal y la nuestra por vehículo	Variables de reporte no disponibles	Etapa de detección ya resuelta	Foco explicativo, no predictivo	—

Cuadro 1: Comparación entre los trabajos relacionados y la propuesta del proyecto.

En síntesis, ninguno de los trabajos resuelve el mismo problema, pero en conjunto cubren los tres componentes que necesitamos: [1] provee la metodología experimental para desvíos de ruta con datos de empresa, [2] y [4] muestran cómo se aborda la predicción de duración de eventos con distribuciones asimétricas y datos censurados, y [3] enmarca el problema desde la detección sobre GPS y advierte sobre la heterogeneidad de causas detrás de un desvío.

Referencias

[1] A. Konovalenko, L. M. Hvattum y K. A. H. Iversen. Predicting last-mile delivery route deviations using machine learning. *Expert Systems With Applications*, 298:129921, 2026. https://doi.org/10.1016/j.eswa.2025.129921

[2] A. Grigorev, A.-S. Mihaita, S. Lee y F. Chen. Incident duration prediction using a bi-level machine learning framework with outlier removal and intra–extra joint optimisation. *Transportation Research Part C: Emerging Technologies*, 141:103721, 2022. https://doi.org/10.1016/j.trc.2022.103721

[3] C. Chen, D. Zhang, P. S. Castro, N. Li, L. Sun, S. Li y Z. Wang. iBOAT: Isolation-based online anomalous trajectory detection. *IEEE Transactions on Intelligent Transportation Systems*, 14(2):806–818, 2013.

[4] A. T. Hojati, L. Ferreira, S. Washington y P. Charles. Hazard based models for freeway traffic incident duration. *Accident Analysis & Prevention*, 52:171–181, 2013.