Departamento Teoría de la Computación

Facultad de Informática

Universidad Nacional del Comahue

Laboratorio de inteligencia artificial

Trabajo Práctico Obligatorio Nº 1

Exploración y corpus

Predicción de la duración de desvíos de ruta en flotas de transporte de personal

Apellido y Nombre	**Legajo**	**Email**
Reibold, Sebastian Alejandro	FAI-3854	sebastian.reibold@est.fi.uncoma.edu.ar
Fernandez Gramajo, Bautista	FAI-3874	bautista.fernandez@est.fi.uncoma.edu.ar
Kissner, Davor	FAI-3185	davor.kissner@est.fi.uncoma.edu.ar

Cursado 2026 — 29 de octubre de 2026

Índice

1. Introducción **2**

2. Exploración de los datos **2**

2.1. Las tres colecciones 2

2.2. Hojas de ruta 2

2.3. Desvíos 3

2.4. Rastreo satelital 3

2.5. Cruce entre colecciones 3

3. Construcción del corpus **4**

3.1. Unidad de análisis y variable objetivo 4

3.2. Reglas de armado 4

3.3. Atributos en T_0 4

3.4. El corpus resultante 4

4. Modelos planteados **5**

4.1. Qué se compara 5

4.2. Cómo se mide 6

4.3. Selección de atributos 6

5. Pasos siguientes **6**

1. Introducción

Este documento presenta la exploración de los datos de Tecfield y la construcción del corpus de trabajo del proyecto, que busca estimar, en el instante en que aparece el primer punto fuera de ruta de un vehículo (T_0), cuánto va a durar el desvío. Los números provienen de la ejecución completa del cuaderno de Python `notebooks/01_exploracion_y_modelos.py`, sobre las tres colecciones que entregó la empresa.

El documento se organiza así: la sección 2 describe y caracteriza cada colección y los problemas de calidad encontrados; la sección 3 explica cómo se arma el corpus, con una fila por evento de desvío; la sección 4 presenta los modelos planteados para probar sobre ese corpus; y la sección 5 cierra con los pasos siguientes.

2. Exploración de los datos

2.1. Las tres colecciones

Tecfield proveyó tres colecciones exportadas de MongoDB (Extended JSON, un documento por línea), que suman unos 1,9 GB. Las fechas vienen en UTC y se pasan a hora de Argentina (UTC−3) antes de agrupar por día.

Colección	Filas	Vehículos	Período	Qué contiene
`hojaDeRuta`	5.519	584	22/10/2025 – 09/09/2026	plan del viaje
`desviosHojaRuta`	203.897	584	09/06/2026 – 31/08/2026	puntos fuera de ruta
`rastreoSatelital`	1.683.550	583	12/07/2026 – 31/08/2026	eventos del GPS

Cuadro 1: Tamaño y período de cada colección. En hojas de ruta el período es el de vigencia (`fechaDesde`–`fechaHasta`); en las otras dos, el de las fechas del GPS.

Hay tres rarezas de formato que condicionan todo el procesamiento. El vehículo se llama `vehiculo.id` en hojas de ruta, `flotaId` en desvíos y `flotaID` en rastreo. Las coordenadas son `[lat, lon]` en desvíos y en la ruta planificada, pero `[lon, lat]` en rastreo. Y el trazado de la ruta de cada hoja (calculado con OSRM, un servicio de mapas) pesa el 99 % del archivo de 1,5 GB, así que se descarta al cargar y solo se conservan los datos simples y los conteos.

2.2. Hojas de ruta

Cada hoja asigna a un vehículo un recorrido planificado hacia una obra. De las 5.519 hojas, 5.013 están vencidas y 506 vigentes; corresponden a 62 obras distintas. El tipo de vehículo más frecuente es *Pesada* (2.900 hojas), seguido de *Liviana* (996) y *Rutero* (515). El campo `tipoHDR` es nulo en 2.674 hojas; el resto se reparte entre transporte de personal (1.363), registro de transporte (1.240) y gerenciamiento de viaje (242).

El recorrido de ida mide en promedio 114 km y 112 minutos según OSRM, con 4,2 paradas y 5,2 puntos de paso por hoja. Las hojas llevan en promedio 6,0 pasajeros para 8,0 plazas; entre las 1.560 hojas con plazas informadas la ocupación media es del 66 %, y el 54 % de todas las hojas no tiene ningún pasajero.

2.3. Desvíos

La colección contiene 203.897 puntos fuera de ruta, agrupados por `grupoDesvioId` en 37.720 episodios, de 584 vehículos y 5.523 hojas de ruta distintas. El detector registró el retorno por ubicación en 130.319 puntos y por *timeout* en 68.014 (5.564 sin motivo). La ruta más cercana al punto es la de ida en el 67 % de los casos, la de vuelta en el 19 % y la alternativa en el 14 %. La velocidad es nula en el 28 % de los puntos y `tipoHDR` está presente solo en el 45 %.

Un hallazgo importante es la demora entre el instante en que el GPS midió la posición (`fechaHoraRastreo`) y el momento en que se registró el punto de desvío (`timestamp`). La mediana es de 1 minuto y el percentil 95 de 20, pero el percentil 99 llega a 1.283 minutos y el máximo a 98.698. En 6.768 puntos (3,3 %) la posición GPS tiene más de una hora de antigüedad. Por eso la duración se mide con la hora del GPS y no con la de registro.

En una primera aproximación por episodio (midiendo con la hora de registro), la duración mediana es de 10 minutos, con cuartiles de 4 y 49, pero la media supera las 4 horas (257 minutos): la distribución tiene una cola muy larga. Los episodios tienen una mediana de 3 puntos, y la distancia máxima a la ruta tiene mediana de 4,8 km.

2.4. Rastreo satelital

Son 1.683.550 eventos de 583 vehículos y 113 tipos de evento (posición programada, vehículo detenido, excesos de velocidad, entre otros). El 8 % de las filas (129.634) está exactamente duplicado. De los 4.308 eventos de "límite de velocidad superado", el 10 % informa velocidad igual a cero, lo que vuelve poco confiable ese campo. La velocidad mediana es 0 y la máxima 280 km/h. Hay 2.809 eventos fuera de la Argentina o sin coordenadas.

2.5. Cruce entre colecciones

El vehículo es lo único que une las tres colecciones y además cada desvío apunta a su hoja con `hojaDeRutaId`. La cobertura es casi completa: los 584 vehículos con desvíos tienen hoja de ruta, 583 de ellos aparecen en el rastreo, y los 583 vehículos del rastreo tienen hoja. Solo 4 de los 5.523 identificadores de hoja citados en desvíos no existen en `hojaDeRuta` (79 puntos). Entre desvíos y rastreo no hay un identificador común: hay que cruzar por vehículo y hora.

Aparecen dos problemas de calidad que afectan al corpus:

- **Hojas vencidas.** El 61 % de los puntos (124.588) cae fuera de la vigencia de su hoja de ruta: 792 antes de `fechaDesde` y 123.796 después de `fechaHasta`, con una mediana de 27 días fuera (percentil 90: 88; máximo: 279). Parece que el sistema sigue comparando contra hojas ya vencidas. Solo 3.617 de las 5.519 hojas estaban vigentes durante la ventana del rastreo.
- **Puntos repetidos.** Los 203.897 puntos corresponden a solo 120.943 posiciones GPS distintas (vehículo más hora): un mismo punto se guarda contra varias hojas de ruta, de modo que un mismo desvío puede aparecer repetido.

También hay que notar que el rastreo comienza el 12/07/2026 y los desvíos el 09/06/2026, por lo que los desvíos anteriores a esa fecha no pueden tener rastreo previo a T_0.

3. Construcción del corpus

3.1. Unidad de análisis y variable objetivo

La unidad de análisis es el *evento*, es decir, un `grupoDesvioId`, y no la lectura. El instante T_0 es el primer `fechaHoraRastreo` del evento, y la variable objetivo y es la diferencia, en segundos, entre el último y el primer `fechaHoraRastreo`. El evento cierra cuando el vehículo retoma la ruta o cuando el detector alcanza su tope de cuatro horas.

3.2. Reglas de armado

1. Se descartan las lecturas con posición $(0, 0)$ (un GPS sin señal) o con fecha fuera de 2025–2026.
2. Se agrupan las lecturas válidas por `grupoDesvioId`: del primer ping salen los atributos de T_0 (ordenado por hora del GPS, y por distancia y posición para desempatar), y de todo el grupo salen la cantidad de lecturas y la duración y.
3. Se agregan los datos de la hoja de ruta correspondiente y se calcula si estaba vigente en T_0.
4. Cuando un mismo desvío se guardó contra varias hojas, se deja un solo evento por vehículo y T_0, prefiriendo el de la hoja vigente.
5. Se calcula el comportamiento del vehículo en los 10 minutos anteriores a T_0 (sin incluir T_0) con una búsqueda del último y del primer GPS de la ventana.
6. Se entrena solo con eventos de dos o más lecturas y duración mayor a cero. Los que llegan al tope de cuatro horas se separan: no corresponden a un retorno medido.

Solo se usa información disponible en T_0. Quedan afuera los campos de retorno, la cantidad de lecturas del evento y todo lo posterior a T_0, para que el modelo no use información del futuro.

3.3. Atributos en T_0

Se definieron 23 atributos en tres grupos, según su origen.

Grupo	**Atributos**
Primer ping	distancia a la ruta, velocidad y si viene vacía, ruta más cercana (ida, vuelta o alternativa), latitud, longitud, hora, día de la semana y franja (madrugada, mañana, tarde, noche)
Hoja de ruta	tipo de vehículo, tipo de hoja, obra, largo y duración estimada de la ida, plazas, pasajeros y si la hoja estaba vigente en T_0
Rastreo previo	cantidad de GPS, velocidad media y última, minutos desde el último GPS, desplazamiento en línea recta y rumbo, todo en los 10 minutos previos a T_0

Cuadro 2: Atributos conocidos en T_0.

3.4. El corpus resultante

La duración en el corpus tiene mediana de 20,4 minutos y percentil 90 de 115,8 minutos (cuartiles de 10 y 53 minutos). La figura 1 muestra la distribución, con la cola hacia el tope de cuatro horas.

Paso	Eventos
Eventos con lecturas válidas	37.720
Repetidos contra otra hoja (mismo vehículo y T_0)	2.007
Una sola lectura o duración cero (se descartan)	19.240
Llegan al tope de 4 h (aparte, sin retorno medido)	2.841
Corpus para entrenar	**13.632**

Cuadro 3: De los eventos a los datos de entrenamiento. El corpus final cubre 556 vehículos.

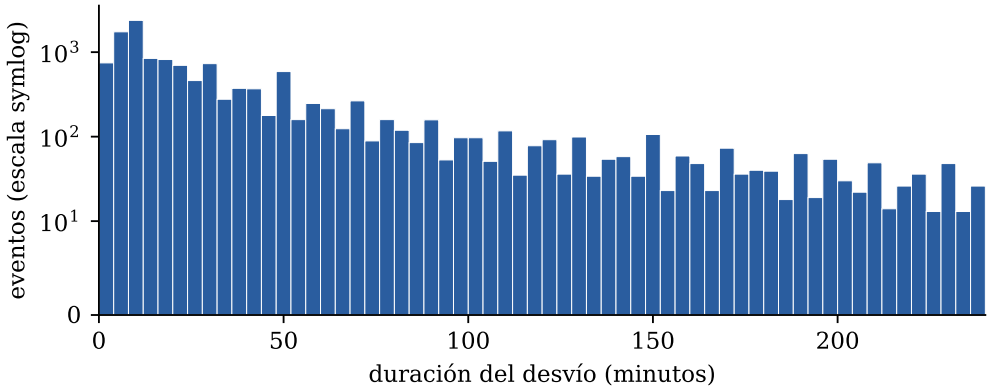


Figura 1: Duración de los desvíos del corpus, en barras de 4 minutos.

La cobertura de los atributos es desigual. Solo 7.854 de los 13.632 eventos (58 %) tienen algún GPS en los 10 minutos previos, y para solo 1.838 hay rumbo (hacen falta dos o más puntos). La velocidad del primer ping falta en 2.247 eventos y 6.804 no tienen `tipoHDR`. El 99,99 % de los eventos tiene hoja de ruta asociada.

4. Modelos planteados

Con el corpus armado, se plantea comparar tres formas de predecir la duración de un desvío. Todavía no se probaron: esta sección define qué se va a probar y cómo se va a medir.

4.1. Qué se compara

- **Referencia:** predecir siempre la misma duración, la mediana de los desvíos de entrenamiento. Es lo mínimo que un modelo tiene que superar.
- **Árbol de decisión:** hace una serie de preguntas sobre el desvío (por ejemplo, si la distancia a la ruta supera cierto valor o si es de noche) y termina en una duración estimada. Se limita su tamaño para que no memorice los casos.
- **Bosque aleatorio (*Random Forest*):** promedia las respuestas de 200 árboles de decisión distintos.
- **Refuerzo de gradiente (*gradient boosting*):** arma árboles de a uno, y cada uno corrige los errores de los anteriores.

Los tres aprenderían la duración en escala logarítmica, $\log(1 + y)$, porque hay muchos desvíos cortos y pocos muy largos; así los largos no dominan el aprendizaje, como sugiere el enfoque de modelos de duración de Hojati et al. [3].

4.2. Cómo se mide

Para saber si un modelo sirve, se lo prueba con vehículos que no vio al entrenar. Los vehículos se reparten en cinco grupos y cada grupo se usa una vez como prueba, mientras los otros cuatro sirven de entrenamiento (validación cruzada por vehículo). Konovalenko et al. [1] separan los datos por fecha; acá se separa por vehículo para que el modelo no memorice cómo se comporta cada móvil.

El error se mide en minutos con dos números: el error promedio (la diferencia absoluta media entre la duración predicha y la real, conocido como MAE) y el error mediano. Además se calcula en qué porcentaje mejora el error promedio respecto de la referencia.

4.3. Selección de atributos

Los 23 atributos del cuadro 2 se pueden quitar o agregar para ver si con menos ya alcanza. Se plantea sumar los grupos de a uno (primer ping, hoja de ruta, rastreo previo) y medir el error cada vez, para saber cuánto aporta cada uno. Hay que tener en cuenta que falta GPS previo en el 42 % de los eventos, lo que limita lo que puede aportar el último grupo.

5. Pasos siguientes

Quedan los siguientes puntos:

- Entrenar y evaluar los tres modelos con la validación por vehículo descrita arriba.
- Decidir con Tecfield qué hacer con los desvíos medidos contra hojas ya vencidas (61 % de los puntos) y cómo deduplicar los puntos repetidos.
- Tratar los 2.841 eventos que llegan al tope de cuatro horas como datos censurados con modelos de supervivencia [3], en lugar de dejarlos aparte.
- Modelar por separado los eventos cortos y los largos, con una etapa previa de clasificación [2], y evaluar el tratamiento de valores atípicos de la variable objetivo.
- Reportar el error por segmentos de interés operativo (tipo de vehículo, franja horaria, obra), y no solo el global.

Referencias

[1] A. Konovalenko, L. M. Hvattum y K. A. H. Iversen. Predicting last-mile delivery route deviations using machine learning. *Expert Systems With Applications*, 298:129921, 2026.

[2] A. Grigorev, A.-S. Mihaita, S. Lee y F. Chen. Incident duration prediction using a bi-level machine learning framework with outlier removal and intra–extra joint optimisation. *Transportation Research Part C: Emerging Technologies*, 141:103721, 2022.

[3] A. T. Hojati, L. Ferreira, S. Washington y P. Charles. Hazard based models for freeway traffic incident duration. *Accident Analysis & Prevention*, 52:171–181, 2013.