INFORME DE AVANCE · 21/10/2026

TP1: dónde estamos

Predicción de la duración de desvíos de ruta en flotas de transporte de personal (Tecfield). Qué tenemos hecho, qué se habló en la reunión del 15/10, qué llevamos a la consulta del jueves 22/10 y cuándo se estima la segunda entrega.

Grupo 5 · Reibold, Sebastian Alejandro (FAI-3854) · Fernandez Gramajo, Bautista (FAI-3874) · Kissner, Davor (FAI-3185)

1. Qué tenemos hecho

La primera entrega está cerrada y el dataset de Tecfield ya está explorado. Falta construir el corpus y empezar a modelar.

#	QUÉ	DETALLE	
1	**Primera entrega**	Motivación, objetivo general y cuatro específicos, introducción y trabajos relacionados con cuadro comparativo. Versión del 28/09, actualizada el 15/10.	HECHO
2	**Problema definido**	Predecir en T_0 (primer ping fuera de ruta) cuántos segundos dura el desvío, por `grupoDesvioId`, comparando contra la mediana con partición por vehículo.	HECHO
3	**Dataset recibido**	Tres colecciones de Tecfield: `desviosHojaRuta`, `hojaDeRuta` y `rastreoSatelital` (≈ 1,9 GB en JSON).	HECHO
4	**Notebook de exploración**	`explorar.py` en marimo: carga las tres colecciones y calcula cobertura, períodos y calidad de los datos.	HECHO
5	**Explicación y diagramas**	Explicación exportada a HTML y tres diagramas: modelo de datos, cómo nace un desvío y línea de tiempo.	HECHO
6	**Corpus y modelos**	Panel evento a evento, selección de atributos y primeros experimentos.	PENDIENTE

TRABAJOS RELACIONADOS

TRABAJO	QUÉ TOMAMOS PARA EL PROYECTO
Konovalenko et al. (2026)	Desvíos en última milla. *Benchmarks* históricos, selección incremental de atributos, MAE y RMSE.
Grigorev et al. (2022)	Duración de incidentes viales. Separar eventos cortos y largos, tratar *outliers*, ensambles de árboles.
Chen et al. (2013) · iBOAT	Trayectorias anómalas en GPS. Advierte que los desvíos mezclan causas distintas.
Hojati et al. (2013)	Modelos de supervivencia. Eventos censurados por el tope de 4 h y escala logarítmica.

2. El dataset en números

Calculado con `explorar.py` sobre la exportación del 04/09/2026. Fechas en hora de Argentina.

VENTANAS DE TIEMPO

COLECCIÓN	PERÍODO	USO
hojaDeRuta	Octubre 2025 – septiembre 2026	El plan del viaje: recorrido, paradas y ruta OSRM.
desviosHojaRuta	Junio – agosto 2026	Las lecturas del detector; de acá sale el evento y la duración.
rastreoSatelital	12/07 – 31/08/2026	GPS previo a T_0. Es la ventana común de las tres.

ANTES DE USARLO

1. **El 61 % de los desvíos cae fuera de la vigencia de su hoja** — A CONSULTAR

   124.588 puntos son posteriores a `fechaHasta`, a 27 días de mediana. Parecería que el sistema sigue comparando contra hojas ya vencidas.

2. **Puntos repetidos contra distintas hojas** — LIMPIEZA

   Un mismo punto GPS se guarda varias veces. Para medir hay que contar posiciones (vehículo + hora), no filas.

3. **Coordenadas y fechas** — LIMPIEZA

   `[lat, lon]` en desvíos y `[lon, lat]` en rastreo. Las fechas vienen en UTC y hay que pasarlas a UTC−3. El vehículo se llama distinto en cada colección: `flotaId`, `flotaID` y `vehiculo.id`.

3. Qué se habló en la reunión del 15/10

Reunión con la cátedra sobre los próximos pasos después de la primera entrega.

1. **Próximo paso**

   Elaborar algún experimento de los trabajos relacionados con nuestros datos, para alcanzar el objetivo acordado con Manuel (Tecfield).

2. **Lo más difícil es el corpus**

   Hay que unir las tres colecciones en **un único corpus**; los modelos ya están implementados. Implica limpiar, sacar atributos redundantes, combinar o transformar campos (por ejemplo, discretizar valores continuos) y extraer patrones de campos como la fecha.

3. **Atributos por experimentación**

   Probar con distintos subconjuntos. Si con dos atributos ya se predice bien, no hace falta un tercero.

4. **Comparar dos o tres modelos**

   Como hizo otro grupo: el mismo corpus a un árbol de decisión y a otro algoritmo, y comparar sus predicciones contra un *benchmark*. Es prueba y error.

5. **Los papers son un punto de partida**

   Sirven para ver qué datos, atributos y técnicas usan; no hay que replicarlos y se pueden combinar ideas de dos. El de Konovalenko predice *si* habrá desvío; el de incidentes predice *cuánto dura* el evento, como el nuestro.

6. **Entregas**

   La **segunda**, en dos o tres semanas, es un incremento: trabajos relacionados, análisis del dataset, algoritmos elegidos y algunos experimentos, con un horizonte claro. La **final** lleva experimentos reales y conclusiones.

7. **Pendientes del grupo**

   Mostrar el notebook más avanzado la semana siguiente y resolver cómo compartir marimo, que hoy se corre en local. Manuel queda disponible para consultas.

4. Para mañana, jueves 22/10

Consulta del jueves con la cátedra. Lo que hay que llevar resuelto o preguntado.

- [ ] **Mostrar el notebook** — LLEVAR

  `explorar.py` corriendo, con las ventanas de tiempo y los problemas de calidad de la página 2. Es lo que quedamos en mostrar en la reunión.

- [ ] **Consultar los problemas de calidad** — PREGUNTAR

  ¿Los desvíos contra hojas vencidas son válidos o se descartan? ¿Cómo deduplicamos los puntos repetidos? Si hace falta, llevarlo a Manuel.

- [ ] **Proponer el corpus** — LLEVAR

  Un registro por `grupoDesvioId`, con la duración *y* en segundos. Solo eventos con 2 lecturas o más y duración mayor a 0; los que llegan al tope de 4 h, aparte. **Atributos en T_0:** distancia mínima, velocidad y si viene vacía, ruta más cercana, posición, hora y franja, tipo de vehículo y de hoja, largo y duración OSRM, y velocidad y rumbo de los 5–10 minutos previos.

- [ ] **Proponer los modelos a comparar** — LLEVAR

  Mediana como *baseline*, árbol de decisión y un ensamble (Random Forest o *gradient boosting*) sobre log(*y*). Partición por vehículo; MAE y error mediano como métricas.

- [ ] **Confirmar la segunda entrega** — PREGUNTAR

  Fecha exacta y qué tiene que incluir. Definir también cómo compartimos el notebook entre los tres.

Ojo: el corpus y los modelos de esta página son nuestra propuesta, armada con el enunciado de Tecfield y los trabajos relacionados. Todavía no los validó la cátedra.

5. Cronograma y segunda entrega

Fechas cumplidas y estimadas. Los jueves son el horario fijo de consulta del grupo.

1

Primera entrega — 28/09

Motivación, objetivos y trabajos relacionados. Versión actualizada el 15/10.

HECHO

2

Reunión con la cátedra — 15/10

Próximos pasos: corpus, atributos y comparación de modelos.

HECHO

3

Consulta del jueves — 22/10

Notebook, dudas de calidad, propuesta de corpus y modelos.

MAÑANA

4

Segunda entrega — 29/10 – 05/11

Análisis de trabajos relacionados y del dataset, corpus construido, algoritmos elegidos y primeros experimentos.

ESTIMADA

5

Entrega final — A definir

Experimentos completos, comparación contra *baselines* y conclusiones.

SIN FECHA

SEGUNDA ENTREGA · ESTIMADA

29/10 – 05/11

En la reunión del 15/10 se habló de **dos o tres semanas**.
La fecha exacta se confirma en la consulta del **jueves 22/10**.