Departamento Teoría de la Computación

Facultad de Informática

Universidad Nacional del Comahue

Laboratorio de inteligencia artificial

Trabajo Práctico Obligatorio Nº 1

Parte 3: entrenamiento de los modelos y explicación de los resultados

Predicción de la duración de desvíos de ruta en flotas de transporte de personal

Apellido y Nombre	**Legajo**	**Email**
Reibold, Sebastian Alejandro	FAI-3854	sebastian.reibold@est.fi.uncoma.edu.ar
Fernandez Gramajo, Bautista	FAI-3874	bautista.fernandez@est.fi.uncoma.edu.ar
Kissner, Davor	FAI-3185	davor.kissner@est.fi.uncoma.edu.ar

Cursado 2026 — 7 de noviembre de 2026

Índice

1. Introducción **2**

2. El corpus en breve **2**

3. Primera etapa: modelos base **3**

3.1. Por qué se predice el logaritmo de la duración 3

3.2. Referencia: la mediana 3

3.3. Árbol de decisión 3

3.4. Random Forest 3

3.5. Detalles técnicos 4

3.6. Cómo se evalúa 4

3.7. Métricas 4

3.8. Resultados de la primera etapa 5

3.9. Aporte de cada grupo de atributos 5

4. Segunda etapa: mejoras **5**

4.1. Una métrica más: el RMSE 6

4.2. Modelos de gradient boosting 6

4.3. Importancia de las variables 6

4.4. Qué variables separan primero el árbol 8

5. Comparación de todos los modelos **8**

6. Conclusiones **9**

6.1. Lo que muestran los resultados 9

6.2. Limitaciones y pasos siguientes 9

1. Introducción

El trabajo plantea una **regresión**: en el instante T_0 en que aparece el primer punto fuera de ruta de un vehículo, y usando solo la información disponible hasta ese momento, predecir cuántos segundos va a durar el desvío. Esta parte presenta los modelos entrenados sobre el corpus, cómo se los evalúa y qué resultados dan.

El trabajo se hizo en dos etapas. En la primera se armaron una referencia (la mediana), un árbol de decisión y un Random Forest, y se midieron con el error absoluto medio. Después de revisar esos resultados con los docentes y el equipo de Tecfield se decidió mejorar tres cosas: agregar una métrica más (el RMSE), analizar qué variables pesan más en los modelos y en qué orden separa el árbol los desvíos, y probar un modelo nuevo, XGBoost. La sección 2 resume el corpus, la sección 3 describe la primera etapa, la sección 4 las mejoras y la sección 5 compara todos los modelos. La sección 6 reúne las conclusiones.

Todo el trabajo está en el cuaderno de marimo `notebooks/01_exploracion_y_modelos.py`, con *polars* para las tablas y *scikit-learn* y *XGBoost* para los modelos. Los números de este documento salen de su ejecución completa.

2. El corpus en breve

La unidad de análisis es el *evento* de desvío (todas las lecturas de una misma salida de ruta) y la variable objetivo y es su duración en segundos, medida con la hora del GPS. El corpus tiene **13.632 eventos** de **556 vehículos**, con una mediana de 20,4 minutos y un percentil 90 de 115,8 minutos: la distribución tiene cola larga. Los eventos que llegan al tope de cuatro horas del detector no se usan para entrenar.

Cada evento tiene **23 atributos**, todos conocidos en T_0, en tres grupos (cuadro 1). Cinco son categóricos: ruta más cercana, franja horaria, tipo de vehículo, tipo de hoja y obra. No se usa ningún dato posterior a T_0, para que los modelos no vean el futuro.

Grupo	Cant.	Atributos
Primer ping	9	distancia a la ruta, velocidad y si viene vacía, ruta más cercana, latitud, longitud, hora, día de la semana y franja
Hoja de ruta	8	tipo de vehículo, tipo de hoja, obra, kilómetros y minutos de la ida, plazas, pasajeros y si la hoja estaba vigente en T_0
Rastreo previo	6	cantidad de GPS, velocidad media y última, minutos desde el último GPS, desplazamiento y rumbo, en los 10 minutos previos a T_0

Cuadro 1: Atributos conocidos en T_0.

La cobertura es desigual: el 42 % de los eventos no tiene ningún GPS en los 10 minutos previos (les faltan los 6 atributos del rastreo previo) y 6.804 eventos no tienen tipo de hoja.

3. Primera etapa: modelos base

3.1. Por qué se predice el logaritmo de la duración

Las duraciones son muy desparejas: la mayoría de los desvíos dura minutos y unos pocos duran horas. Si el modelo aprende la duración tal cual, esos pocos casos pesan demasiado. Por eso los modelos aprenden $\log(1 + y)$, que achica las diferencias grandes, y al predecir se vuelve a segundos con $e^{\hat{z}} - 1$. Se suma 1 para poder tomar el logaritmo de una duración igual a cero.

3.2. Referencia: la mediana

Predice **siempre la misma duración**, la mediana de los desvíos de entrenamiento (unos 20 minutos), sin mirar ningún atributo. Es lo que haría un operador sin modelo, y es el piso que hay que superar. Se eligió la mediana y no el promedio porque, entre las predicciones constantes, es la que comete el menor error absoluto medio: es la referencia constante más difícil de superar.

3.3. Árbol de decisión

Un árbol de decisión hace una serie de preguntas sobre el desvío, una detrás de otra. Cada respuesta lleva el desvío por una rama distinta hasta una *hoja*, y la predicción es la duración típica de los desvíos de entrenamiento que llegaron a esa hoja. Se lo limita para que no memorice los datos (cuadro 2). Su ventaja es que se puede dibujar y explicar; su límite es que es *inestable*: un cambio chico en los datos puede cambiarle toda la estructura.

Parámetro	Valor	Para qué
`max_depth`	8	como máximo 8 preguntas seguidas
`min_samples_leaf`	30	cada hoja reúne al menos 30 desvíos
`random_state`	0	resultados repetibles

Cuadro 2: Árbol de decisión (`DecisionTreeRegressor`). Entrenado con todo el corpus termina con 153 hojas.

3.4. Random Forest

Entrena **200 árboles** y los hace distintos a propósito: cada uno aprende con una muestra de los desvíos sorteada con reposición, de modo que ve los datos de una forma un poco diferente y se equivoca de otra manera. La predicción final es el **promedio de los 200**, y al promediar los errores que van para un lado se compensan con los que van para el otro. Esto corrige la inestabilidad del árbol solo. La configuración (cuadro 3) es una primera elección, sin ajustar.

Parámetro	Valor	Para qué
`n_estimators`	200	cantidad de árboles
`min_samples_leaf`	10	cada hoja de cada árbol reúne al menos 10 desvíos
`random_state`	0	resultados repetibles

Cuadro 3: Random Forest (`RandomForestRegressor`).

3.5. Detalles técnicos

Los atributos de texto se pasan a los modelos como códigos $0, 1, 2, \ldots$; el árbol los trata como si tuvieran un orden que no tienen, lo que es una limitación. Los datos faltantes (por ejemplo, el rastreo previo de un vehículo que no mandó GPS) no se completan: los propios árboles deciden por qué rama mandar el desvío, lo que requiere scikit-learn 1.3 o superior en el árbol y 1.4 o superior en el bosque.

3.6. Cómo se evalúa

Para saber si un modelo funciona hay que probarlo con desvíos que no vio al entrenar. Se usa una **validación cruzada por vehículo** de cinco particiones: los 556 vehículos se reparten en cinco grupos, todos los desvíos de un vehículo quedan en el mismo grupo, y se entrena con cuatro grupos para predecir el quinto, cinco veces (cuadro 4). Así cada uno de los 13.632 desvíos tiene una predicción hecha por un modelo que nunca vio a su vehículo, y el error se calcula una sola vez sobre todas juntas.

	Grupo 1	**Grupo 2**	**Grupo 3**	**Grupo 4**	**Grupo 5**
Vuelta 1	prueba	entrena	entrena	entrena	entrena
Vuelta 2	entrena	prueba	entrena	entrena	entrena
Vuelta 3	entrena	entrena	prueba	entrena	entrena
Vuelta 4	entrena	entrena	entrena	prueba	entrena
Vuelta 5	entrena	entrena	entrena	entrena	prueba

Cuadro 4: Validación cruzada por vehículo.

Se separa por vehículo y no al azar porque, si no, un mismo vehículo podría estar en entrenamiento y en prueba, y el modelo aprendería sus costumbres y parecería mejor de lo que es. Lo que importa en la práctica es cómo predice para un vehículo que nunca vio. Konovalenko et al. [1] separan los datos por fecha, con la misma intención.

3.7. Métricas

El **error** de cada desvío es la diferencia, sin signo, entre la duración predicha y la real. Con esos errores se calculan estas medidas, que conviene ver con un ejemplo inventado de cuatro desvíos (cuadro 5).

Desvío	**Duró (min)**	**Predicción (min)**	**Error (min)**
A	10	15	5
B	20	18	2
C	30	40	10
D	120	50	70

Cuadro 5: Ejemplo inventado para explicar las métricas.

- **Error absoluto medio (MAE).** Es el promedio de los errores: en promedio, por cuántos minutos se equivoca el modelo. En el ejemplo, $(5 + 2 + 10 + 70)/4 = 21{,}75$ minutos. Es la **métrica principal**.

- **Error mediano.** Es la mediana de los errores: la mitad de las predicciones se equivoca menos que este valor. En el ejemplo, $(5 + 10)/2 = 7{,}5$ minutos.
- **Mejora.** Qué parte del MAE de la referencia le saca el modelo: mejora $= 1 - \frac{\text{MAE del modelo}}{\text{MAE de la mediana}}$. Para la propia referencia es cero.

3.8. Resultados de la primera etapa

Modelo	MAE (min)	Error mediano (min)	Mejora
Mediana (referencia)	32,1	15,0	—
Árbol de decisión	28,8	14,3	10 %
Random Forest	27,0	13,0	16 %

Cuadro 6: Primera etapa: error con los 23 atributos, en validación cruzada por vehículo.

Si se predice siempre la duración típica, el error promedio es de 32,1 minutos y la mitad de las veces se erra por menos de 15. El árbol baja el MAE a 28,8 minutos (10 % de mejora) y el Random Forest a 27,0 (16 %), con la mitad de sus predicciones a menos de 13 minutos del valor real. Las dos métricas ordenan los modelos igual. En los tres casos el MAE es bastante mayor que el error mediano: unos pocos desvíos muy largos, con errores grandes, suben el promedio.

3.9. Aporte de cada grupo de atributos

Para saber de dónde sale la mejora se entrenó el Random Forest tres veces, sumando un grupo de atributos por vez y con la misma validación (cuadro 7).

Atributos del Random Forest	Cant.	MAE (min)	RMSE (min)	Mejora
Solo primer ping	9	29,4	50,2	8 %
+ Hoja de ruta	17	27,0	45,7	16 %
+ Rastreo previo	23	27,0	45,8	16 %

Cuadro 7: Random Forest sumando los grupos de atributos de a uno.

Solo con el primer ping el bosque ya mejora un 8 % a la referencia. Al sumar la hoja de ruta la mejora se duplica. Al sumar el rastreo previo el error no cambia: ese grupo no aporta información nueva, algo esperable si se recuerda que le falta al 42 % de los eventos.

4. Segunda etapa: mejoras

Al presentar estos resultados, el equipo docente y Tecfield sugirieron tres mejoras: **agregar una métrica más**, el RMSE; **analizar qué variables importan**, tanto en los modelos de bosque como en el árbol, donde interesa saber cuáles son las primeras que separan los desvíos; y **probar un modelo más**, de la familia de *gradient boosting* (XGBoost). Se hicieron las tres.

4.1. Una métrica más: el RMSE

El **RMSE** (raíz del error cuadrático medio) eleva los errores al cuadrado antes de promediarlos y saca la raíz al final, de modo que queda en minutos como el MAE:

$$\text{RMSE} = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(\hat{y}_i - y_i)^2}.$$

Al elevar al cuadrado, los errores grandes pesan mucho más. En el ejemplo del cuadro 5 el RMSE es $\sqrt{(25+4+100+4900)/4} = 35{,}5$ minutos, contra 21,75 de MAE: el desvío D, con 70 minutos de error, domina el resultado. Por eso las dos métricas se complementan: el MAE dice cuánto se equivoca el modelo *en general* y el RMSE cuánto lo castigan los errores grandes. Para este problema, donde hay pocos desvíos muy largos, la diferencia entre ambos es informativa. El RMSE es 1,7 veces el MAE en el mejor modelo (45,8 contra 27,0 minutos), lo que confirma que el error se concentra en los desvíos largos.

4.2. Modelos de gradient boosting

A diferencia del bosque, que promedia árboles independientes, el *gradient boosting* arma los árboles **de a uno**, y cada árbol nuevo intenta corregir los errores que dejaron los anteriores. Se usan árboles chicos y muchos pasos pequeños. XGBoost es una implementación de esta idea que acepta datos faltantes sin completarlos. Se probó con una configuración inicial, sin ajustar (cuadro 8), y con las mismas cinco particiones por vehículo.

Parámetro	**Valor**
cantidad de árboles (`n_estimators`)	300
paso de aprendizaje (`learning_rate`)	0,05
tamaño del árbol	`max_depth`=4
mínimo por hoja	`min_child_weight`=10
fracción de desvíos por árbol (`subsample`)	0,8
`random_state`	0

Cuadro 8: Configuración de XGBoost.

4.3. Importancia de las variables

Cada modelo de árboles permite medir la *importancia* de cada atributo: cuánto reduce el error, sumando todas las preguntas que se hacen sobre él. Las importancias de cada modelo suman 1. Se calcularon entrenando cada modelo una vez con el corpus completo (la figura 1 muestra los atributos más importantes). Son importancias *del modelo*, no de la realidad: dicen qué usó el modelo para predecir, no qué causa la duración.

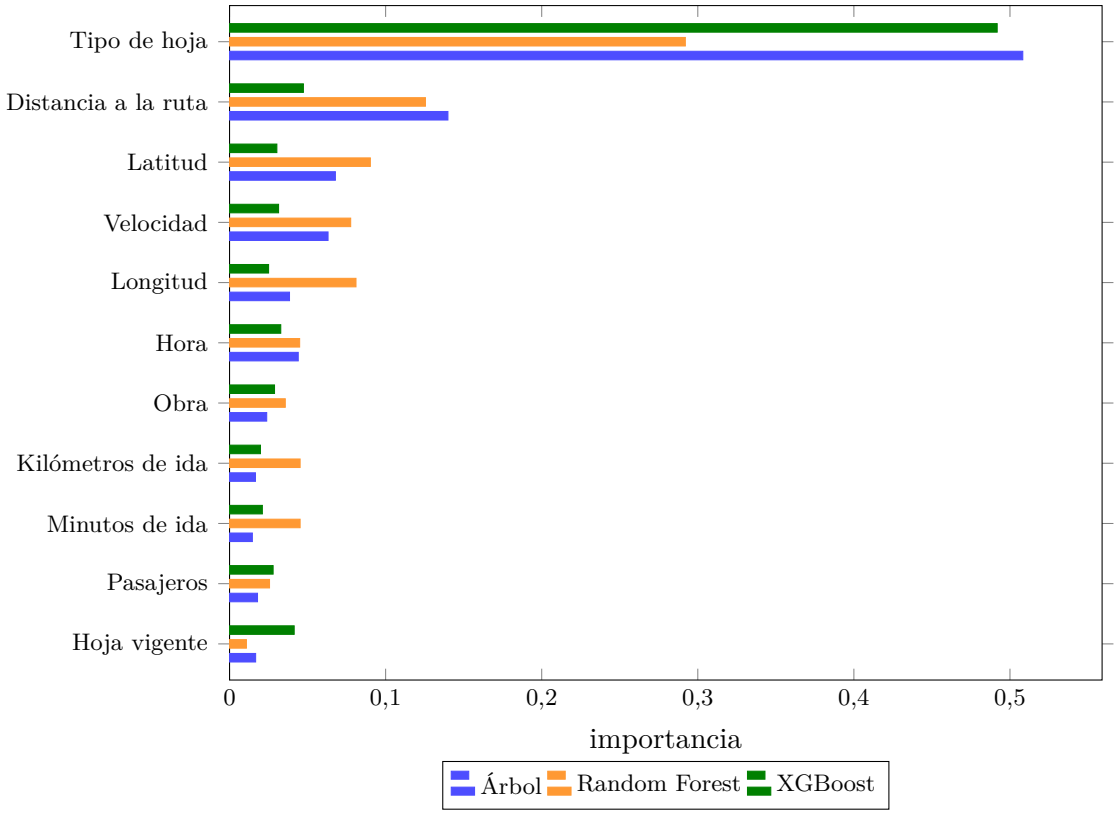


Figura 1: Atributos más importantes de cada modelo (la unión de los ocho primeros de cada uno).

Los tres modelos coinciden en lo principal:

- El **tipo de hoja** es el atributo más importante en todos, con entre el 29 % (Random Forest) y el 51 % (árbol) del total.
- Le siguen la **distancia a la ruta** y la **posición** (latitud y longitud) y la **velocidad** del primer ping, además de la hora del desvío.
- Los atributos del **rastreo previo** pesan poco.

Sumando por grupo (cuadro 9), la hoja de ruta y el primer ping explican casi todo, y el rastreo previo no supera el 10 % en ningún modelo, lo que coincide con el análisis por grupos de la sección anterior.

Grupo	**Árbol**	**Random Forest**	**XGBoost**
Primer ping	37 %	45 %	22 %
Hoja de ruta	61 %	48 %	68 %
Rastreo previo	3 %	7 %	10 %

Cuadro 9: Importancia total de cada grupo de atributos.

El tipo de hoja destaca porque no es un dato cualquiera: cuando está informado los desvíos duran mucho más (sección siguiente) y falta en la mitad de los eventos, de modo que su ausencia también es información. Conviene preguntarle a Tecfield qué distingue a esas hojas.

4.4. Qué variables separan primero el árbol

La figura 2 muestra las tres primeras preguntas del árbol entrenado con todo el corpus. En cada nodo figura la cantidad de desvíos que llegan y su duración mediana.

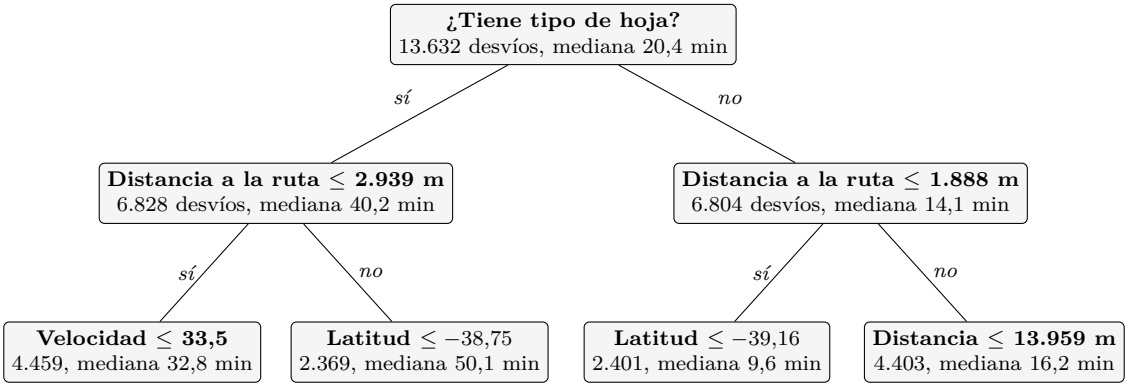


Figura 2: Primeros tres niveles del árbol de decisión.

Se leen tres cosas:

- **La primera pregunta es el tipo de hoja.** Separa dos grupos muy distintos: los 6.828 desvíos que lo traen informado tienen una mediana de **40 minutos** y los 6.804 que no, de **14 minutos**. Unos duran casi el triple que otros. Es el mismo atributo que los tres modelos marcan como el más importante.
- **La segunda pregunta es la misma en las dos ramas**: qué tan lejos de la ruta estaba el vehículo en el primer ping. Con tipo de hoja, los desvíos que se alejaron más de unos 2,9 km tienen una mediana de 50 minutos.
- **El tercer nivel usa la velocidad y la posición**, y el cuarto agrega pasajeros, hoja vigente, obra, hora y minutos desde el último GPS. El árbol llega a 8 niveles.

Ningún atributo del rastreo previo aparece antes del cuarto nivel, y ahí solo uno (minutos desde el último GPS), lo que es consistente con su baja importancia.

5. Comparación de todos los modelos

Modelo	MAE (min)	RMSE (min)	Error mediano (min)	Mejora MAE
Mediana (referencia)	32,1	54,2	15,0	—
Árbol de decisión	28,8	47,5	14,3	10 %
Random Forest	**27,0**	**45,8**	**13,0**	16 %
XGBoost	27,3	46,1	13,1	15 %

Cuadro 10: Error de cada modelo con los 23 atributos, en validación cruzada por vehículo. Cuanto más bajo el error, mejor. En negrita, el mejor valor de cada métrica.

El cuadro 10 muestra que:

- **Todos los modelos le ganan a la referencia** en las tres métricas, y el árbol queda último entre los tres modelos en las tres.

- **Random Forest y XGBoost quedan casi empatados.** El Random Forest tiene el menor error en las tres métricas, pero la diferencia es chica: 0,3 minutos de MAE, 0,3 de RMSE y 0,1 de error mediano. No se midió cuánto varía con otra semilla ni con otras particiones, por lo que no alcanza para decir que uno es mejor que otro.
- **El RMSE confirma que el error está en los desvíos largos.** Es alrededor de 1,7 veces el MAE en todos los modelos, y la referencia, que no distingue largos de cortos, es la que más lo sufre (54,2 min).
- **El boosting no mejoró al bosque con esta configuración.** Los parámetros de ambos son una primera elección sin ajustar, así que esto no descarta que con ajuste XGBoost pueda superarlo.

6. Conclusiones

6.1. Lo que muestran los resultados

Hay señal. Con la información de T_0 se puede predecir algo de la duración de un desvío: los tres modelos le ganan a la referencia con vehículos que no vieron al entrenar, y el mejor reduce el MAE de 32,1 a 27,0 minutos y el RMSE de 54,2 a 45,8, cerca de un 16 % en ambos.

La señal está en el tipo de hoja y en el primer ping. Los análisis de importancia y la estructura del árbol apuntan a lo mismo: el tipo de hoja, y luego la distancia a la ruta y la posición. El rastreo previo casi no aporta.

Pero la mejora es modesta. El mejor modelo se equivoca 27 minutos en promedio y la duración mediana de un desvío es de 20 minutos. El error sigue siendo grande, sobre todo en los desvíos largos.

6.2. Limitaciones y pasos siguientes

- **El error real sería mayor.** Los 2.841 desvíos que llegan al tope de cuatro horas no están en el corpus y son los más difíciles de predecir, así que el error medido es optimista. Una opción es tratarlos como datos censurados con modelos de supervivencia [3].
- **Los modelos no están ajustados.** Los parámetros de todos son una primera elección; falta probar cuáles dan el menor error.
- **Las categorías entran como números**, con un orden que no tienen.
- **Las importancias son del modelo, no causales**, y las de los árboles favorecen a los atributos con muchos valores distintos.
- **Hojas vencidas.** El 61 % de los puntos de desvío cae fuera de la vigencia de su hoja de ruta. Se mantuvieron y se marcaron, pero si no son desvíos válidos habría que sacarlos.
- **Falta rastreo al principio.** El rastreo empieza un mes después que los desvíos, por lo que esos eventos no pueden tener rastreo previo.
- **Siguientes pasos:** modelar por separado los desvíos cortos y largos con una etapa previa de clasificación [2], y reportar el error por segmentos operativos (tipo de vehículo, franja horaria, obra) y no solo el global.

Referencias

[1] A. Konovalenko, L. M. Hvattum y K. A. H. Iversen. Predicting last-mile delivery route deviations using machine learning. *Expert Systems With Applications*, 298:129921, 2026.

[2] A. Grigorev, A.-S. Mihaita, S. Lee y F. Chen. Incident duration prediction using a bi-level machine learning framework with outlier removal and intra–extra joint optimisation. *Transportation Research Part C: Emerging Technologies*, 141:103721, 2022.

[3] A. T. Hojati, L. Ferreira, S. Washington y P. Charles. Hazard based models for freeway traffic incident duration. *Accident Analysis & Prevention*, 52:171–181, 2013.