FACULTAD DE INFORMÁTICA · UNCOMA

Laboratorio de Inteligencia Artificial

TP1 · Predicción de la duración de desvíos de ruta

Grupo 5 Sebastián Bautista Davor

CON TECFIELD · CURSADO 2026



MAPA DE LA PRESENTACIÓN

Cinco partes, tres voces

1 El problema

2 Los datos

3 El notebook

4 El corpus

5 Los modelos

B Bautista

PARTE 1

El corpus

De 37.720 eventos a una tabla para entrenar

S Sebastián

PARTE 2

Árbol de decisión

Modelo 1 · interpretable

D Davor

PARTE 3

Random Forest

Modelo 2 · 200 árboles

TECFIELD · TRANSPORTE DE PERSONAL

LA FLOTA

Tecfield lleva personal a obras y yacimientos

HOJA DE RUTA

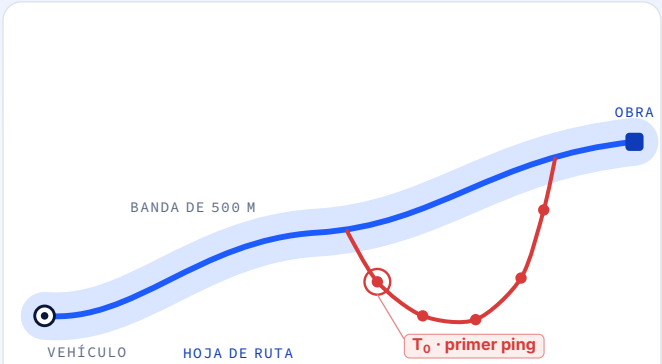
Cada vehículo tiene su recorrido planificado

DETECTOR

Compara la posición GPS contra ese recorrido

DESVÍO

A más de 500 m de la ruta registra lecturas de desvío



Al primer punto fuera de ruta lo llamamos T_0. En ese instante, nadie sabe cuánto va a durar el desvío.

EL PRIMER PING

T_0

El primer punto fuera de ruta.
Nadie sabe cuál de los dos viene.

Futuro 1 **Toma una calle alternativa y vuelve**



Futuro 2 **Queda afuera de la ruta**



EL DETECTOR GENERA

100.000

lecturas de desvío por mes

COLA DE ALERTAS

- Alerta de desvío — Prioridad igual
- Alerta de desvío — Prioridad igual
- Alerta de desvío — Prioridad igual

OBJETIVO

Una regresión

NO HAY ETIQUETAS DEL MOTIVO

① ~~Falla de GPS~~
② ~~Hoja de ruta mal configurada~~
③ ~~Vehículo mal asignado~~
④ ~~Recorrido distinto~~

LO QUE SÍ QUEDA REGISTRADO

Cuánto duró el desvío

Siempre queda anotado.



ENTRADA · EN T_0

Solo lo que se sabe hasta ese momento

Primer ping | Hoja de ruta | Rastreo previo

$f(x)$
Modelo

SALIDA

Duración del desvío

¿? segundos

Alerta temprana — En el primer ping, estimar cuánto va a durar.

LA VARIABLE OBJETIVO

La unidad es el evento, no la lectura

EVENTO = TODAS LAS LECTURAS DE UN MISMO `grupoDesvioId`



UNIDAD DE ANÁLISIS

El detector ya agrupa las lecturas de una misma salida de ruta con un identificador: `grupoDesvioId`.

OJO CON EL RELOJ

Se usa `fechaHoraRastreo` (cuándo midió el GPS), no `timestamp` (cuándo escribió el detector).

EL TOPE DE 4 HORAS

El detector corta a las 4 h: un evento que llega ahí no tiene un regreso a la ruta medido.

TRES COLECCIONES · EXPORTADAS DE MONGODB · CASI 2 GB DE JSON

Los datos de Tecfield

desviosHojaRuta

98 MB

Las lecturas del detector. De acá salen los **eventos** y la **duración**.

hojaDeRuta

1,5 GB

El plan del viaje: paradas, pasajeros y el trazado OSRM del recorrido.

rastreoSatelital

284 MB

El GPS crudo de cada vehículo: lo que venía haciendo **antes** de T_0.

TRAMPAS QUE APARECIERON AL EXPLORAR

Coordenadas invertidas

Desvíos: `[lat, lon]`. GPS: `[lon, lat]`

Fechas en hora universal

Se pasan a la hora de Argentina

Tres nombres para el vehículo

`flotaId`, `flotaID`, `vehiculo.id`

Hojas vencidas

El 61 % de los desvíos cae fuera de la vigencia de su hoja

Desvíos repetidos

Un mismo punto se guarda contra varias hojas

TODO EL TRABAJO EN UN SOLO ARCHIVO

Un notebook de marimo

marimo `polars` `altair` `scikit-learn`

1 Explorar

Qué hay en cada colección y qué trampas tiene

2 Armar el corpus

Una fila por evento, con atributos en T_0

3 Comparar modelos

Mediana, árbol de decisión y Random Forest

CARGA

Lee los JSON de a un documento. De las hojas de ruta descarta la geometría: es casi todo el peso.

LIMPIEZA

Fechas a hora de Argentina, coordenadas acomodadas y un solo nombre para el vehículo: `flota`.

REACTIVO

Un selector de atributos: sacás uno, el modelo se entrena de nuevo solo y muestra cómo cambia el error.

UNA FILA POR DESVÍO · ATRIBUTOS EN T_0 Y LA DURACIÓN

Siete pasos para armar el corpus

1. **Lecturas válidas**
   Se tiran las de posición `[0, 0]` o con fecha fuera de 2025–2026.

2. **Un registro por evento**
   Se agrupa por `grupoDesvioId`. T_0 es el primer ping: distancia, velocidad y posición.

3. **Hoja de ruta**
   Se cruza con la hoja: obra, tipo de vehículo, largo y duración OSRM, vigencia.

4. **Sin repetidos**
   Uno por vehículo y T_0, prefiriendo la hoja vigente.

5. **Rastreo previo**
   El GPS de los 10 minutos antes de T_0 (`join_asof`), sin tocar el propio T_0.

6. **Fecha y hora**
   Hora, día de la semana y franja del día.

7. **Filtro final**
   2 lecturas o más, duración mayor a 0 y menos de 4 horas.

SIN FUGAS

Solo se usa información de T_0 o anterior. Nada del final del desvío.

CUÁNTOS EVENTOS QUEDAN

De 37.720 eventos a 13.632

37.720
eventos de partida

−2.007
repetidos

−19.240
una sola lectura o duración 0

−2.841
tope de 4 horas

13.632
eventos en el corpus



Aparte **No se tiran**
El detector cortó: no hay retorno medido.

de 556 vehículos

ATRIBUTOS CANDIDATOS · TODOS SE CONOCEN EN T_0

Los atributos vienen de tres lugares

1 Primer ping

Lo que mide el primer GPS fuera de ruta

`distancia_m` `velocidad` `velocidad_vacia` `ruta_cercana` `lat` `lon` `hora` `dia_semana` `franja`

2 Hoja de ruta

Lo que dice la hoja del viaje

`tipoVehiculo` `tipoHDR` `obra_id` `km_ida` `min_ida` `plazas` `pasajeros` `hoja_vigente`

3 Rastreo previo

Qué hizo en los 10 min anteriores

`gps_previos` `vel_media_previa` `vel_ultima` `min_desde_ultimo_gps` `desplaz_previo_m` `rumbo_previo`

Fugas: nunca entran

Sería hacer trampa

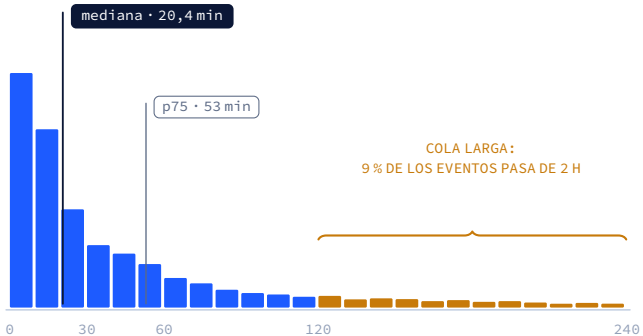
~~`retorno.*`~~
Cómo terminó el desvío

~~`lecturas`~~
Cuántas lecturas tuvo

`GPS posterior a` T_0
Cualquier dato posterior

DURACIÓN DE LOS DESVÍOS · 13.632 EVENTOS

¿Cómo son las duraciones?



Duración del desvío (min) · cada barra junta 10 min

LA MITAD

dura menos de 20 minutos. Cuartiles: 10 y 53 min.

POCOS EVENTOS, MUY LARGOS

La media (42 min) duplica a la mediana.

LOS MODELOS APRENDEN

$z = \log(1 + y)$

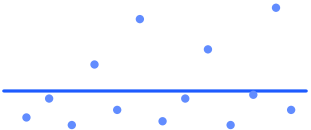
Al predecir se vuelve a segundos: $y = \exp(z) - 1$

REFERENCIA, MÉTRICAS Y VALIDACIÓN

La referencia: la mediana

REFERENCIA

Predecir siempre la mediana



32,1

min de error medio (MAE) de la referencia

MÉTRICAS

Error medio y error mediano

5 eventos de ejemplo, en minutos



`mediano = 14 (el del medio)`

VALIDACIÓN CRUZADA

5 particiones por vehículo



Nunca en entrenamiento y prueba a la vez.

CONTRA ESA REFERENCIA COMPARAMOS DOS MODELOS

Árbol de decisión

Modelo 1

Random Forest

Modelo 2

MODELO 1

Árbol de decisión

NODO

Una pregunta sobre un atributo.

RAMA

La respuesta: sí o no. Lleva al nodo siguiente.

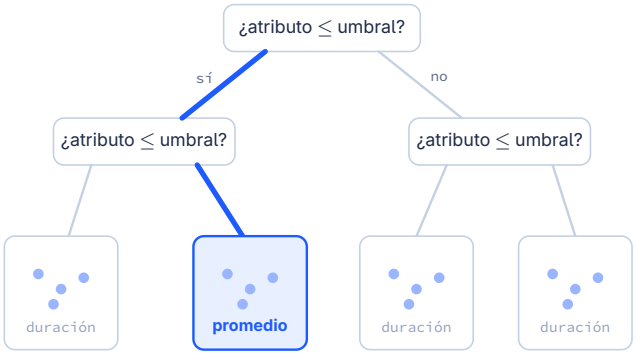
HOJA

Donde termina el recorrido.

PREDICCIÓN

Promedio de los eventos de entrenamiento de esa hoja.

EJEMPLO ILUSTRATIVO



NUESTRO ÁRBOL · ENTRENADO CON LOS 13.632 EVENTOS

¿Trae el tipo de hoja?



Y SIGUE HASTA 8 NIVELES DE PROFUNDIDAD

CÓMO LO LIMITAMOS

8
niveles de profundidad

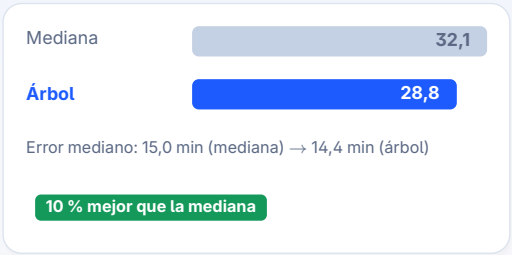
30
eventos por hoja, como mínimo

153
hojas en total

`DecisionTreeRegressor`

ERROR MEDIO (MAE) · EN MINUTOS

Resultado: 28,8 minutos



ÁRBOL DE DECISIÓN

28,8 min

de error medio por evento

Ventaja

Se puede dibujar y explicar

Ejemplo: ¿tipoHDR informado? sí → ¿distancia ≤ 2.938 m? sí → ¿velocidad ≤ 33,5? no → ≈ 37 min

Límite

Un solo árbol es inestable

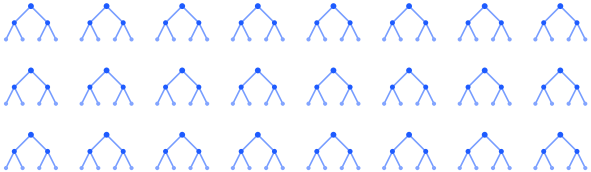
Un cambio chico en los datos de entrenamiento le cambia toda la estructura: otra raíz, otras preguntas.

MODELO 2

Random Forest

Un bosque de árboles de decisión, no uno solo.

200 árboles



200 ÁRBOLES DISTINTOS

CADA ÁRBOL, UNA MUESTRA DISTINTA

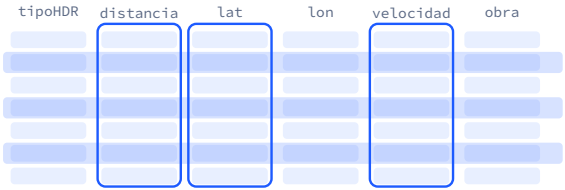
Se entrena con eventos elegidos al azar, con repetición.

CADA PREGUNTA, ATRIBUTOS DISTINTOS

En cada pregunta mira solo un subconjunto de los atributos.

TABLA DE ENTRENAMIENTO

FILA = EVENTO · COLUMNA = ATRIBUTO



LA PREDICCIÓN FINAL

ejemplo ilustrativo

Cada árbol se equivoca distinto

ÁRBOL 1
18 min

ÁRBOL 2
31 min

ÁRBOL 3
24 min

ÁRBOL 4
27 min

· · · y 196 árboles más

PROMEDIO DE LOS 200 · PREDICCIÓN FINAL
25 min

Errores respecto del valor real: −8, +5, −2, +1. Al promediar se compensan en parte.



RANDOM FOREST · IMPORTANCIA DE CADA ATRIBUTO

¿Qué atributos pesan más?



CASI TODO

Del primer ping y de la hoja de ruta

El rastreo previo casi no aparece.

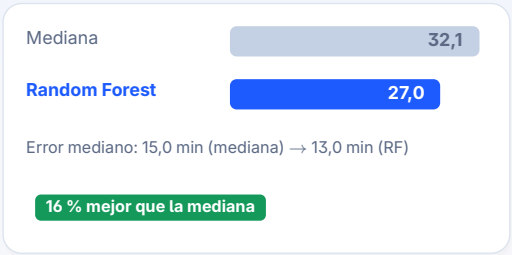
CÓMO LO CONFIGURAMOS

```
n_estimators = 200
min_samples_leaf = 10
n_jobs = −1
random_state = 0
```

Aprende `log(1 + y)`.

ERROR MEDIO (MAE) · EN MINUTOS

Resultado: 27,0 minutos



RANDOM FOREST

27,0 min

de error medio por evento

Ventaja

El mejor de los dos modelos

Más estable que un solo árbol y casi no hace falta ajustar parámetros.

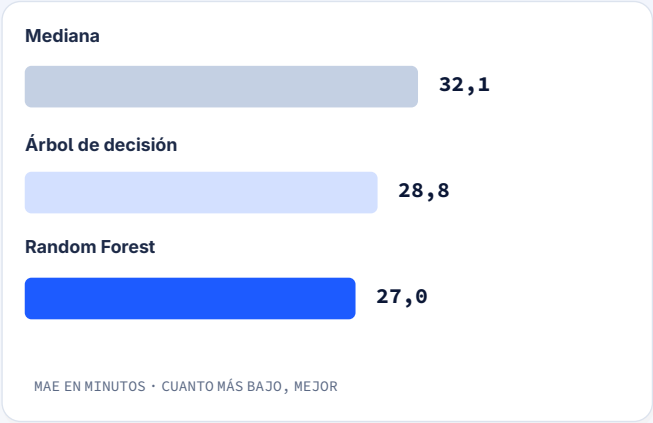
Límite

Más difícil de explicar

Son 200 árboles, no uno. Y no ajustamos hiperparámetros: son una elección inicial.

VALIDACIÓN CRUZADA POR VEHÍCULO · 5 PARTICIONES

Lado a lado: el error de cada modelo



MEDIANA (BASELINE)

32,1 min · error mediano 15,0

ÁRBOL DE DECISIÓN

28,8 min · error mediano 14,4

10 % mejor

RANDOM FOREST

27,0 min · error mediano 13,0

16 % mejor El mejor de los dos

RANDOM FOREST · MAE EN MINUTOS

Sumando grupos de atributos



¿POR QUÉ EL RASTREO PREVIO NO AYUDA?



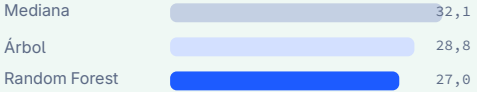
Sin GPS previo: antes de T_0 no hay ninguna lectura del vehículo.

CONCLUSIÓN

Le ganan a la mediana, pero por poco

Hay señal

Los dos modelos bajan el error medio frente a la mediana.



Falta mejorar

El error sigue siendo grande y al rastreo previo le falta información.

27,0 min
error medio del mejor modelo

42 %
de los eventos sin GPS previo

PENDIENTES

Lo que llevamos para seguir

1 Ajustar hiperparámetros

Profundidad, hoja mínima y cantidad de árboles hoy son una elección inicial.

2 Eventos del tope como censurados

Tratar los de 4 h como datos censurados (Hojati et al., 2013).

3 Cortos y largos por separado

Un clasificador previo y un modelo por grupo, como propone Grigorev et al. (2022).

4 Hojas vencidas

Confirmar con Tecfield si los desvíos contra hojas vencidas son válidos.

Predecir, en el primer ping, cuánto va a durar un desvío.